

Estadística descriptiva en R para biomedicina

Meta de las dos sesiones

Al finalizar, podremos transformar un archivo CSV en un reporte descriptivo reproducible.

Sesión 1

Datos, limpieza, normalidad y estadísticos descriptivos.

Sesión 2

Tabla académica, gráficos y redacción de resultados.

Flujo de trabajo

- 1 Importar** Leer el archivo CSV.
- 2 Inspeccionar** Reconocer variables, tipos y valores ausentes.
- 3 Limpiar** Definir qué observaciones entran al análisis.
- 4 Evaluar** Combinar gráficos con Shapiro-Wilk.
- 5 Resumir** Elegir media $\pm$ DE o mediana (Q1-Q3).
- 6 Reportar** Construir tabla, figura y texto.

SESIÓN 1

Del archivo CSV al resumen estadístico

Datos biomédicos de ejemplo

id	grupo	Hb (g/dL)	PCR (mg/L)
PX01	Control	12.4	0.2
PX02	Estable	11.9	0.6
PX03	Activa	11.5	0.8
PX04	Control	13.1	0.3
PX05	Estable	12.7	0.8

36 pacientes

Tres categorías clínicas

Dos biomarcadores

Datos sintéticos y
anónimos

Hb: hemoglobina. PCR: proteína C reactiva. Cuatro filas contienen un valor ausente.

Carga del archivo CSV

```
library(readr)

datos <- read_csv(
  "datos/biomarcadores_clinicos.csv",
  show_col_types = FALSE
)
```

Cómo leer el código

La asignación `<-` significa “guardar en”. El objeto `datos` queda disponible para los pasos siguientes.

Inspección inicial

```
head(datos)      # primeras 6 filas  
glimpse(datos)   # columnas y tipos  
summary(datos)   # resumen y NA  
colSums(is.na(datos))
```

Preguntas útiles

- ▶ ¿Cada fila es una observación?
- ▶ ¿Las unidades son claras?

Resultado esperado

- ▶ 36 filas y 4 columnas
- ▶ 2 NA en cada biomarcador

Limpieza de valores ausentes

```
datos_limpios <- datos |>
  drop_na(hemoglobina_g_dl, pcr_mg_l)

nrow(datos)          # 36
nrow(datos_limpios)  # 32
```

Decisión que debe quedar registrada

El ejercicio elimina filas incompletas para las dos variables analizadas. En un estudio real primero se investiga por qué faltan esos datos.

Una forma larga para comparar variables


```
datos_largos <- datos_limpios |>
  pivot_longer(
    cols = c(hemoglobina_g_dl, pcr_mg_l),
    names_to = "variable",
    values_to = "valor"
  )
```

Esta transformación permite repetir el mismo gráfico y el mismo cálculo para varias variables.

Histogramas

```
ggplot(datos_largos,  
       aes(x = valor)) +  
  geom_histogram(bins = 10) +  
  facet_wrap(~ variable,  
            scales = "free")
```


Buscamos simetría, colas y valores extremos.



Gráficos Q-Q

```
ggplot(datos_largos,  
       aes(sample = valor)) +  
  stat_qq() +  
  stat_qq_line() +  
  facet_wrap(~ variable,  
            scales = "free")
```

Los puntos cercanos a la línea apoyan normalidad.



Shapiro-Wilk como apoyo a la decisión

H₀: los datos son compatibles con una distribución normal.

Resultado	Decisión práctica	Resumen sugerido
$p \geq 0.05$	No rechazamos H ₀	Media $\pm$ DE
$p < 0.05$	Rechazamos H ₀	Mediana (Q1-Q3)

El valor p se interpreta junto con el histograma, el gráfico Q-Q y el contexto biológico.

Prueba de normalidad en R

```
normalidad <- datos_largos |>
  group_by(variable) |>
  summarise(
    W = unname(shapiro.test(valor)$statistic),
    p = shapiro.test(valor)$p.value
  )
```

Variable	W	p	Lectura
Hemoglobina	0.977	0.713	Compatible con normalidad
PCR	0.531	< 0.001	Distribución asimétrica

Dos formas de resumir una variable

Paramétrica

Media: centro aritmético

DE: dispersión alrededor de la media

Reporte: media $\pm$ DE

No paramétrica

Mediana: observación central

RIQ: intervalo de Q1 a Q3

Reporte: mediana (Q1-Q3)

Calculamos ambas para aprender. Reportamos la que corresponde a la distribución.

Cálculo de los descriptivos

```
descriptivos <- datos_largos |>
  group_by(variable, grupo) |>
  summarise(
    n = n(),
    media = mean(valor), DE = sd(valor),
    mediana = median(valor),
    Q1 = quantile(valor, 0.25),
    Q3 = quantile(valor, 0.75)
  )
```

SESIÓN 2

De los resultados al reporte

Anatomía de una tabla académica

- ▶ Número y título breve encima de la tabla.
- ▶ Unidades dentro de los encabezados.
- ▶ Tamaño muestral visible.
- ▶ Pocas líneas horizontales y ningún adorno innecesario.
- ▶ Abreviaturas explicadas en una nota.

Vancouver regula principalmente las referencias. La revista define los detalles de sus tablas.

Construcción de la tabla con gt

```
tabla_academica <- tabla_reporte |>
  gt(groupname_col = "medida") |>
  cols_label(
    grupo = "Grupo clínico",
    resultado = "Resumen",
    p_shapiro = "p de Shapiro-Wilk"
  ) |>
  tab_header(title = "Tabla 1. Estadística descriptiva")
```

El script exporta versiones HTML, CSV y LaTeX.

Tabla 1. Estadística descriptiva de los biomarcadores

Medida	Grupo	n	Resumen	<i>p</i>	Reporte
Hemoglobina	Control	10	14.00 ± 0.80	0.713	Media ± DE
Hemoglobina	Activa	11	13.40 ± 1.02	0.713	Media ± DE
Hemoglobina	Estable	11	13.61 ± 0.93	0.713	Media ± DE
PCR	Control	10	0.8 (0.5–1.0)	< 0.001	Mediana (Q1–Q3)
PCR	Activa	11	2.8 (1.5–5.4)	< 0.001	Mediana (Q1–Q3)
PCR	Estable	11	1.2 (0.9–1.6)	< 0.001	Mediana (Q1–Q3)

DE: desviación estándar. Q1–Q3: rango intercuartílico. Normalidad evaluada por variable.

Gráfico para una variable normal

```
ggplot(datos_limpios,  
       aes(grupo, hemoglobina_g_dl,  
           color = grupo)) +  
  geom_jitter(width = 0.12) +  
  stat_summary(fun = mean,  
              geom = "point") +  
  stat_summary(fun.data = mean_sdl,  
              geom = "errorbar")
```

Mostramos datos individuales, media
y DE.





Gráfico para una variable asimétrica

```
ggplot(datos_limpios,  
       aes(grupo, pcr_mg_l,  
           fill = grupo)) +  
  geom_boxplot(  
    outlier.shape = NA,  
    alpha = 0.45  
  ) +  
  geom_jitter(width = 0.12)
```

La caja muestra mediana y RIQ. Los puntos conservan la información original.



Variable compatible con normalidad

La hemoglobina fue compatible con una distribución normal (Shapiro-Wilk, $W = 0.977$, $p = 0.713$), por lo que se resumió como media $\pm$ DE.

Variable asimétrica

La proteína C reactiva mostró una distribución asimétrica (Shapiro-Wilk, $W = 0.531$, $p < 0.001$), por lo que se resumió como mediana (Q1-Q3).

Estas frases describen los datos. Todavía no prueban diferencias entre grupos clínicos.

Límites de esta primera aproximación

- ▶ Shapiro-Wilk no reemplaza la inspección visual.
- ▶ Una muestra pequeña puede ocultar desviaciones de normalidad.
- ▶ Una muestra grande puede detectar desviaciones poco importantes.
- ▶ Eliminar NA puede introducir sesgo si la ausencia no ocurre al azar.
- ▶ En análisis inferencial suele evaluarse la distribución de los residuos.

La decisión estadística también depende de la pregunta y del diseño experimental.

Cambie una parte del flujo y vuelva a ejecutarlo:

1. Añada una variable biológica nueva al CSV.
2. Prediga si su distribución será simétrica o asimétrica.
3. Genere histograma, Q-Q y Shapiro-Wilk.
4. Produzca el resumen y el gráfico correspondientes.

La meta es reproducir el flujo y explicar cada decisión.

-  Ghasemi A, Zahediasl S. Normality tests for statistical analysis: a guide for non-statisticians. Int J Endocrinol Metab. 2012;10(2):486-489.
-  Wickham H. ggplot2: Elegant Graphics for Data Analysis. 2nd ed. Cham: Springer; 2016.
-  R Core Team. R: A language and environment for statistical computing. Vienna: R Foundation for Statistical Computing.

El script completo contiene comentarios, exportaciones y frases modelo.